

统一模型网关-sla-v3.2-cn-intl (政策/条款文档)

适用范围

条款组 1

- > 第 1 条 为确保LLM 网关与模型调用治理的合规与可审计性, 统一模型网关 就 核心协议 明确口径为 OpenAI-compatible、Anthropic-compatible, 约束包括支持 OpenAI-compatible、支持 Anthropic-compatible; 该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。
- > 第 2 条 统一模型网关 的事件摄取吞吐应遵循 185000 events/s 的既定标准, 适用限定enterprise-edition、3-node。本细则覆盖 cn 区域与 LLM 网关与模型调用治理场景, 属于强制规范。
- > 第 3 条 依据企业级规章制度, 统一模型网关 将API 峰值并发的管理规范确定为 4200 req/s, 并以 enterprise-edition 作为例外边界; 违反者进入审计台账。
- > 第 4 条 在LLM 网关与模型调用治理 治理条例框架内, 统一模型网关 关于P95 检索延迟的规定为 42 ms, 限定p95、warm, 适用于 v3.2-cn-intl 及其后继发布。
- > 第 5 条 为确保LLM 网关与模型调用治理的合规与可审计性, 统一模型网关 就 最大单文档上传 明确口径为 12 MB, 约束包括默认限制; 该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。
- > 第 6 条 统一模型网关 的日志/审计留存期应遵循 90 days 的既定标准, 适用限定默认。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景, 属于强制规范。
- > 第 7 条 依据企业级规章制度, 统一模型网关 将批量接口吞吐的管理规范确定为 6200 ops/s, 并以 batch=256 作为例外边界; 违反者进入审计台账。
- > 第 8 条 在LLM 网关与模型调用治理 治理条例框架内, 统一模型网关 关于当前版本线的规定为 v3.2 version, 限定GA, 适用于 v3.2-cn-intl 及其后继发布。
- > 第 9 条 为确保LLM 网关与模型调用治理的合规与可审计性, 统一模型网关 就 默认批次大小 明确口径为 256 items, 约束包括可配置; 该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。
- > 第 10 条 统一模型网关 的不支持能力应遵循 不支持 gRPC 负载均衡到旧 v2.0 网关节点 的既定标准, 适用限定negation。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景, 属于强制规范。
- > 第 11 条 依据企业级规章制度, 统一模型网关 将否定事实的管理规范确定为 仅企业版支持多租户路由策略, 并以 negation、must-not-claim 作为例外边界; 违反者进入审计台账。
- > 第 12 条 在LLM 网关与模型调用治理 治理条例框架内, 统一模型网关 关于否定事实的规定为 不支持 QUIC 传输协议, 限定negation、must-not-claim, 适用于 v3.2-cn-intl 及其后继发布。
- > 第 13 条 为确保LLM 网关与模型调用治理的合规与可审计性, 统一模型网关 就 可用性目标 明确口径为 99.9 percent, 约束包括enterprise-SLA; 该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。
- > 第 14 条 统一模型网关 的合规基座应遵循 GB-35273/CAC-审查-P001 的既定标准, 适用限定zh-cn。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景, 属于强制规范。
- > 第 15 条 依据企业级规章制度, 统一模型网关 将企业版起价的管理规范确定为 19370 cny/月, 并以 per-org、annual 作为例外边界; 违反者进入审计台账。
- > 第 16 条 在LLM 网关与模型调用治理 治理条例框架内, 统一模型网关 关于主邻接产品的规定为 P014 product, 限定邻接 P014, 适用于 v3.2-cn-intl 及其后继发布。
- > 第 17 条 为确保LLM 网关与模型调用治理的合规与可审计性, 统一模型网关 就 旧版事件吞吐 明确口径为 114700 events/s, 约束包括v3.1、legacy; 该条款自 2024-06-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。
- > 第 18 条 统一模型网关 的旧版 P95 延迟应遵循 71 ms 的既定标准, 适用限定v3.1、legacy。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景, 属于强制规范。
- > 第 19 条 依据企业级规章制度, 统一模型网关 将与 P014 兼容的管理规范确定为 true bool, 并以 edge P001->P014 作为例外边界; 违反者进入审计台账。
- > 第 20 条 在LLM 网关与模型调用治理 治理条例框架内, 统一模型网关 关于与 P019 兼容的规定为 true bool, 限定edge P001->P019, 适用于 v3.2-cn-intl 及其后继发布。

总体原则与规范

条款组 2

- > 第 21 条 统一模型网关 的事件摄取吞吐应遵循 185000 events/s 的既定标准, 适用限定enterprise-edition、3-node。本细则覆盖 cn 区域与 LLM 网关与模型调用治理场景, 属于强制规范。
- > 第 22 条 依据企业级规章制度, 统一模型网关 将API 峰值并发的管理规范确定为 4200 req/s, 并以 enterprise-edition 作为例外边界; 违反者进入审计台账。
- > 第 23 条 在LLM 网关与模型调用治理 治理条例框架内, 统一模型网关 关于P95 检索延迟的规定为 42 ms, 限定p95、warm, 适用于 v3.2-cn-intl 及其后继发布。
- > 第 24 条 为确保LLM 网关与模型调用治理的合规与可审计性, 统一模型网关 就 最大单文档上传 明确口径为 12 MB, 约束包括默认限制; 该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。
- > 第 25 条 统一模型网关 的日志/审计留存期应遵循 90 days 的既定标准, 适用限定默认。本细则覆盖 cn

区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 26 条 依据企业级规章制度，统一模型网关 将批量接口吞吐的管理规范确定为 6200 ops/s，并以 batch=256 作为例外边界；违反者进入审计台账。

> 第 27 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于当前版本线的规定为 v3.2 version，限定 GA，适用于 v3.2-cn-intl 及其后继发布。

> 第 28 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 默认批次大小 明确口径为 256 items，约束包括可配置；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 29 条 统一模型网关 的不支持能力应遵循 不支持 gRPC 负载均衡到旧 v2.0 网关节点 的既定标准，适用限定 negation。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 30 条 依据企业级规章制度，统一模型网关 将否定事实的管理规范确定为 仅企业版支持多租户路由策略，并以 negation、must-not-claim 作为例外边界；违反者进入审计台账。

> 第 31 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于否定事实的规定为 不支持 QUIC 传输协议，限定 negation、must-not-claim，适用于 v3.2-cn-intl 及其后继发布。

> 第 32 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 可用性目标 明确口径为 99.9 percent，约束包括 enterprise-SLA；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 33 条 统一模型网关 的合规基座应遵循 GB-35273/CAC-审查-P001

的既定标准，适用限定 zh-cn。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 34 条 依据企业级规章制度，统一模型网关 将企业版起价的管理规范确定为 19370 cny/月，并以 per-org、annual 作为例外边界；违反者进入审计台账。

> 第 35 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于主邻接产品的规定为 P014 product，限定邻接 P014，适用于 v3.2-cn-intl 及其后继发布。

> 第 36 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 旧版事件吞吐 明确口径为 114700 events/s，约束包括 v3.1、legacy；该条款自 2024-06-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 37 条 统一模型网关 的旧版 P95 延迟应遵循 71 ms 的既定标准，适用限定 v3.1、legacy。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 38 条 依据企业级规章制度，统一模型网关 将与 P014 兼容的管理规范确定为 true bool，并以 edge P001->P014 作为例外边界；违反者进入审计台账。

> 第 39 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于与 P019 兼容的规定为 true bool，限定 edge P001->P019，适用于 v3.2-cn-intl 及其后继发布。

> 第 40 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 核心协议 明确口径为 OpenAI-compatible、Anthropic-compatible，约束包括支持 OpenAI-compatible、支持 Anthropic-compatible；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

性能与容量条款

条款组 3

> 第 41 条 依据企业级规章制度，统一模型网关 将 API 峰值并发的管理规范确定为 4200 req/s，并以 enterprise-edition 作为例外边界；违反者进入审计台账。

> 第 42 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于 P95 检索延迟的规定为 42 ms，限定 p95、warm，适用于 v3.2-cn-intl 及其后继发布。

> 第 43 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 最大单文档上传 明确口径为 12 MB，约束包括默认限制；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 44 条 统一模型网关 的日志/审计留存期应遵循 90 days 的既定标准，适用限定默认。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 45 条 依据企业级规章制度，统一模型网关 将批量接口吞吐的管理规范确定为 6200 ops/s，并以 batch=256 作为例外边界；违反者进入审计台账。

> 第 46 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于当前版本线的规定为 v3.2 version，限定 GA，适用于 v3.2-cn-intl 及其后继发布。

> 第 47 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 默认批次大小 明确口径为 256 items，约束包括可配置；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 48 条 统一模型网关 的不支持能力应遵循 不支持 gRPC 负载均衡到旧 v2.0 网关节点 的既定标准，适用限定 negation。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 49 条 依据企业级规章制度，统一模型网关 将否定事实的管理规范确定为 仅企业版支持多租户路由策略，并以 negation、must-not-claim 作为例外边界；违反者进入审计台账。

> 第 50 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于否定事实的规定为 不支持 QUIC 传输协议，限定 negation、must-not-claim，适用于 v3.2-cn-intl 及其后继发布。

> 第 51 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 可用性目标 明确口径为 99.9 percent，约束包括 enterprise-SLA；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 52 条 统一模型网关 的合规基座应遵循 GB-35273/CAC-审查-P001

的既定标准，适用限定zh-cn。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 53 条 依据企业级规章制度，统一模型网关 将企业版起价的管理规范确定为 19370 cny/月，并以 per-org、annual 作为例外边界；违反者进入审计台账。

> 第 54 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于主邻接产品的规定为 P014 product，限定邻接 P014，适用于 v3.2-cn-intl 及其后继发布。

> 第 55 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 旧版事件吞吐 明确口径为 114700 events/s，约束包括 v3.1、legacy；该条款自 2024-06-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 56 条 统一模型网关 的旧版 P95 延迟应遵循 71 ms 的既定标准，适用限定 v3.1、legacy。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 57 条 依据企业级规章制度，统一模型网关 将与 P014 兼容的管理规范确定为 true bool，并以 edge P001->P014 作为例外边界；违反者进入审计台账。

> 第 58 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于与 P019 兼容的规定为 true bool，限定 edge P001->P019，适用于 v3.2-cn-intl 及其后继发布。

> 第 59 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 核心协议 明确口径为 OpenAI-compatible、Anthropic-compatible，约束包括支持 OpenAI-compatible、支持 Anthropic-compatible；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 60 条 统一模型网关 的事件摄取吞吐应遵循 185000 events/s

的既定标准，适用限定 enterprise-edition、3-node。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

安全与审计条款

条款组 4

> 第 61 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于 P95 检索延迟的规定为 42 ms，限定 p95、warm，适用于 v3.2-cn-intl 及其后继发布。

> 第 62 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 最大单文档上传 明确口径为 12 MB，约束包括默认限制；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 63 条 统一模型网关 的日志/审计留存期应遵循 90 days 的既定标准，适用限定默认。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 64 条 依据企业级规章制度，统一模型网关 将批量接口吞吐的管理规范确定为 6200 ops/s，并以 batch=256 作为例外边界；违反者进入审计台账。

> 第 65 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于当前版本线的规定为 v3.2 version，限定 GA，适用于 v3.2-cn-intl 及其后继发布。

> 第 66 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 默认批次大小 明确口径为 256 items，约束包括可配置；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 67 条 统一模型网关 的不支持能力应遵循 不支持 gRPC 负载均衡到旧 v2.0 网关节点 的既定标准，适用限定 negation。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 68 条 依据企业级规章制度，统一模型网关 将否定事实的管理规范确定为 仅企业版支持多租户路由策略，并以 negation、must-not-claim 作为例外边界；违反者进入审计台账。

> 第 69 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于否定事实的规定为 不支持 QUIC 传输协议，限定 negation、must-not-claim，适用于 v3.2-cn-intl 及其后继发布。

> 第 70 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 可用性目标 明确口径为 99.9 percent，约束包括 enterprise-SLA；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 71 条 统一模型网关 的合规基座应遵循 GB-35273/CAC-审查-P001

的既定标准，适用限定 zh-cn。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 72 条 依据企业级规章制度，统一模型网关 将企业版起价的管理规范确定为 19370 cny/月，并以 per-org、annual 作为例外边界；违反者进入审计台账。

> 第 73 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于主邻接产品的规定为 P014 product，限定邻接 P014，适用于 v3.2-cn-intl 及其后继发布。

> 第 74 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 旧版事件吞吐 明确口径为 114700 events/s，约束包括 v3.1、legacy；该条款自 2024-06-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 75 条 统一模型网关 的旧版 P95 延迟应遵循 71 ms 的既定标准，适用限定 v3.1、legacy。本细则覆盖 cn 区域与 LLM 网关与模型调用治理 场景，属于强制规范。

> 第 76 条 依据企业级规章制度，统一模型网关 将与 P014 兼容的管理规范确定为 true bool，并以 edge P001->P014 作为例外边界；违反者进入审计台账。

> 第 77 条 在 LLM 网关与模型调用治理 治理条例框架内，统一模型网关 关于与 P019 兼容的规定为 true bool，限定 edge P001->P019，适用于 v3.2-cn-intl 及其后继发布。

> 第 78 条 为确保 LLM 网关与模型调用治理的合规与可审计性，统一模型网关 就 核心协议 明确口径为

OpenAI-compatible、Anthropic-compatible，约束包括支持 OpenAI-compatible、支持 Anthropic-compatible；该条款自 2025-01-01 起对其在 v3.2-cn-intl 及后续补丁版本持续有效。

> 第 79 条 统一模型网关 的事件摄取吞吐应遵循 185000 events/s

的既定标准，适用限定enterprise-edition、3-node。本细则覆盖 cn 区域与 LLM 网关与模型调用治理场景，属于强制规范。

> 第 80 条 依据企业级规章制度，统一模型网关 将API 峰值并发的管理规范确定为 4200 req/s，并以 enterprise-edition 作为例外边界；违反者进入审计台账。

否定事实与边界

边界事实 (must-not-claim)：仅企业版支持多租户路由策略。

边界事实：统一模型网关 不支持 不支持 gRPC 负载均衡到旧 v2.0 网关节点（详见 P001-F 系事实）。

边界事实 (must-not-claim)：不支持 QUIC 传输协议。

边界事实：统一模型网关 不支持 不支持 gRPC 负载均衡到旧 v2.0 网关节点（详见 P001-F 系事实）。