

统一模型网关常见问题 (FAQ)

FAQ 章节 1

Q: Q: 统一模型网关 的核心协议 () 是多少?

A: A: 依据 P001-F001: 核心协议 = ['OpenAI-compatible', 'Anthropic-compatible'], 约束 支持 OpenAI-compatible、支持 Anthropic-compatible。

Q: Q: 统一模型网关 的事件摄取吞吐 (events/s) 是多少?

A: A: 依据 P001-F002: 事件摄取吞吐 = 185000 events/s, 约束 enterprise-edition、3-node。

Q: Q: 统一模型网关 的 API 峰值并发 (req/s) 是多少?

A: A: 依据 P001-F003: API 峰值并发 = 4200 req/s, 约束 enterprise-edition。

Q: Q: 统一模型网关 的 P95 检索延迟 (ms) 是多少?

A: A: 依据 P001-F004: P95 检索延迟 = 42 ms, 约束 p95、warm。

Q: Q: 统一模型网关 的最大单文档上传 (MB) 是多少?

A: A: 依据 P001-F005: 最大单文档上传 = 12 MB, 约束 默认限制。

Q: Q: 统一模型网关 的日志/审计留存期 (days) 是多少?

A: A: 依据 P001-F006: 日志/审计留存期 = 90 days, 约束 默认。

Q: Q: 统一模型网关 的批量接口吞吐 (ops/s) 是多少?

A: A: 依据 P001-F007: 批量接口吞吐 = 6200 ops/s, 约束 batch=256。

Q: Q: 统一模型网关 的当前版本线 (version) 是多少?

A: A: 依据 P001-F008: 当前版本线 = v3.2 version, 约束 GA。

Q: Q: 统一模型网关 的默认批次大小 (items) 是多少?

A: A: 依据 P001-F009: 默认批次大小 = 256 items, 约束 可配置。

Q: Q: 统一模型网关 的不支持能力 () 是多少?

A: A: 依据 P001-F010: 不支持能力 = 不支持 gRPC 负载均衡到旧 v2.0 网关节点, 约束 negation。

Q: Q: 统一模型网关 的否定事实 () 是多少?

A: A: 依据 P001-F011: 否定事实 = 仅企业版支持多租户路由策略, 约束 negation、must-not-claim。

Q: Q: 统一模型网关 的否定事实 () 是多少?

A: A: 依据 P001-F012: 否定事实 = 不支持 QUIC 传输协议, 约束 negation、must-not-claim。

Q: Q: 统一模型网关 的可用性目标 (percent) 是多少?

A: A: 依据 P001-F013: 可用性目标 = 99.9 percent, 约束 enterprise-SLA。

Q: Q: 统一模型网关 的合规基座 () 是多少?

A: A: 依据 P001-F014: 合规基座 = GB-35273/CAC-审查-P001, 约束 zh-cn。

Q: Q: 统一模型网关 的企业版起价 (cny/月) 是多少?

A: A: 依据 P001-F015: 企业版起价 = 19370 cny/月, 约束 per-org、annual。

Q: Q: 统一模型网关 的主邻接产品 (product) 是多少?

A: A: 依据 P001-F016: 主邻接产品 = P014 product, 约束 邻接 P014。

Q: Q: 统一模型网关 的旧版事件吞吐 (events/s) 是多少?

A: A: 依据 P001-F017: 旧版事件吞吐 = 114700 events/s, 约束 v3.1、legacy。

Q: Q: 统一模型网关 的旧版 P95 延迟 (ms) 是多少?

A: A: 依据 P001-F018: 旧版 P95 延迟 = 71 ms, 约束 v3.1、legacy。

Q: Q: 统一模型网关 的与 P014 兼容 (bool) 是多少?

A: A: 依据 P001-F019: 与 P014 兼容 = true bool, 约束 edge P001->P014。

Q: Q: 统一模型网关 的与 P019 兼容 (bool) 是多少?

A: A: 依据 P001-F020: 与 P019 兼容 = true bool, 约束 edge P001->P019。

FAQ 章节 2

Q: Q: 统一模型网关 的事件摄取吞吐 (events/s) 是多少?

A: A: 依据 P001-F002: 事件摄取吞吐 = 185000 events/s, 约束 enterprise-edition、3-node。

Q: Q: 统一模型网关 的 API 峰值并发 (req/s) 是多少?

A: A: 依据 P001-F003: API 峰值并发 = 4200 req/s, 约束 enterprise-edition。

Q: Q: 统一模型网关 的 P95 检索延迟 (ms) 是多少?

A: A: 依据 P001-F004: P95 检索延迟 = 42 ms, 约束 p95、warm。

Q: Q: 统一模型网关 的最大单文档上传 (MB) 是多少?

A: A: 依据 P001-F005: 最大单文档上传 = 12 MB, 约束 默认限制。

Q: Q: 统一模型网关 的日志/审计留存期 (days) 是多少?

A: A: 依据 P001-F006: 日志/审计留存期 = 90 days, 约束 默认。

Q: Q: 统一模型网关 的批量接口吞吐 (ops/s) 是多少?

A: A: 依据 P001-F007: 批量接口吞吐 = 6200 ops/s, 约束 batch=256。

Q: Q: 统一模型网关 的当前版本线 (version) 是多少?

A: A: 依据 P001-F008: 当前版本线 = v3.2 version, 约束 GA。

Q: Q: 统一模型网关 的 默认批次大小 (items) 是多少?
A: A: 依据 P001-F009: 默认批次大小 = 256 items, 约束 可配置。
Q: Q: 统一模型网关 的 不支持能力 () 是多少?
A: A: 依据 P001-F010: 不支持能力 = 不支持 gRPC 负载均衡到旧 v2.0 网关节点, 约束 negation。
Q: Q: 统一模型网关 的 否定事实 () 是多少?
A: A: 依据 P001-F011: 否定事实 = 仅企业版支持多租户路由策略, 约束 negation、must-not-claim。
Q: Q: 统一模型网关 的 否定事实 () 是多少?
A: A: 依据 P001-F012: 否定事实 = 不支持 QUIC 传输协议, 约束 negation、must-not-claim。
Q: Q: 统一模型网关 的 可用性目标 (percent) 是多少?
A: A: 依据 P001-F013: 可用性目标 = 99.9 percent, 约束 enterprise-SLA。
Q: Q: 统一模型网关 的 合规基座 () 是多少?
A: A: 依据 P001-F014: 合规基座 = GB-35273/CAC-审查-P001, 约束 zh-cn。
Q: Q: 统一模型网关 的企业版起价 (cny/月) 是多少?
A: A: 依据 P001-F015: 企业版起价 = 19370 cny/月, 约束 per-org、annual。
Q: Q: 统一模型网关 的主邻接产品 (product) 是多少?
A: A: 依据 P001-F016: 主邻接产品 = P014 product, 约束 邻接 P014。
Q: Q: 统一模型网关 的 旧版事件吞吐 (events/s) 是多少?
A: A: 依据 P001-F017: 旧版事件吞吐 = 114700 events/s, 约束 v3.1、legacy。
Q: Q: 统一模型网关 的 旧版 P95 延迟 (ms) 是多少?
A: A: 依据 P001-F018: 旧版 P95 延迟 = 71 ms, 约束 v3.1、legacy。
Q: Q: 统一模型网关 的 与 P014 兼容 (bool) 是多少?
A: A: 依据 P001-F019: 与 P014 兼容 = true bool, 约束 edge P001->P014。
Q: Q: 统一模型网关 的 与 P019 兼容 (bool) 是多少?
A: A: 依据 P001-F020: 与 P019 兼容 = true bool, 约束 edge P001->P019。
Q: Q: 统一模型网关 的核心协议 () 是多少?
A: A: 依据 P001-F001: 核心协议 = ['OpenAI-compatible', 'Anthropic-compatible'], 约束 支持 OpenAI-compatible、支持 Anthropic-compatible。

FAQ 章节 3

Q: Q: 统一模型网关 的 API 峰值并发 (req/s) 是多少?
A: A: 依据 P001-F003: API 峰值并发 = 4200 req/s, 约束 enterprise-edition。
Q: Q: 统一模型网关 的 P95 检索延迟 (ms) 是多少?
A: A: 依据 P001-F004: P95 检索延迟 = 42 ms, 约束 p95、warm。
Q: Q: 统一模型网关 的最大单文档上传 (MB) 是多少?
A: A: 依据 P001-F005: 最大单文档上传 = 12 MB, 约束 默认限制。
Q: Q: 统一模型网关 的 日志/审计留存期 (days) 是多少?
A: A: 依据 P001-F006: 日志/审计留存期 = 90 days, 约束 默认。
Q: Q: 统一模型网关 的 批量接口吞吐 (ops/s) 是多少?
A: A: 依据 P001-F007: 批量接口吞吐 = 6200 ops/s, 约束 batch=256。
Q: Q: 统一模型网关 的 当前版本线 (version) 是多少?
A: A: 依据 P001-F008: 当前版本线 = v3.2 version, 约束 GA。
Q: Q: 统一模型网关 的 默认批次大小 (items) 是多少?
A: A: 依据 P001-F009: 默认批次大小 = 256 items, 约束 可配置。
Q: Q: 统一模型网关 的 不支持能力 () 是多少?
A: A: 依据 P001-F010: 不支持能力 = 不支持 gRPC 负载均衡到旧 v2.0 网关节点, 约束 negation。
Q: Q: 统一模型网关 的 否定事实 () 是多少?
A: A: 依据 P001-F011: 否定事实 = 仅企业版支持多租户路由策略, 约束 negation、must-not-claim。
Q: Q: 统一模型网关 的 否定事实 () 是多少?
A: A: 依据 P001-F012: 否定事实 = 不支持 QUIC 传输协议, 约束 negation、must-not-claim。
Q: Q: 统一模型网关 的 可用性目标 (percent) 是多少?
A: A: 依据 P001-F013: 可用性目标 = 99.9 percent, 约束 enterprise-SLA。
Q: Q: 统一模型网关 的 合规基座 () 是多少?
A: A: 依据 P001-F014: 合规基座 = GB-35273/CAC-审查-P001, 约束 zh-cn。
Q: Q: 统一模型网关 的企业版起价 (cny/月) 是多少?
A: A: 依据 P001-F015: 企业版起价 = 19370 cny/月, 约束 per-org、annual。
Q: Q: 统一模型网关 的主邻接产品 (product) 是多少?
A: A: 依据 P001-F016: 主邻接产品 = P014 product, 约束 邻接 P014。
Q: Q: 统一模型网关 的 旧版事件吞吐 (events/s) 是多少?
A: A: 依据 P001-F017: 旧版事件吞吐 = 114700 events/s, 约束 v3.1、legacy。

Q: Q: 统一模型网关 的 旧版 P95 延迟 (ms) 是多少?

A: A: 依据 P001-F018: 旧版 P95 延迟 = 71 ms, 约束 v3.1、legacy。

Q: Q: 统一模型网关 的 与 P014 兼容 (bool) 是多少?

A: A: 依据 P001-F019: 与 P014 兼容 = true bool, 约束 edge P001->P014。

Q: Q: 统一模型网关 的 与 P019 兼容 (bool) 是多少?

A: A: 依据 P001-F020: 与 P019 兼容 = true bool, 约束 edge P001->P019。

Q: Q: 统一模型网关 的核心协议 () 是多少?

A: A: 依据 P001-F001: 核心协议 = ['OpenAI-compatible', 'Anthropic-compatible'], 约束 支持 OpenAI-compatible、支持 Anthropic-compatible。

Q: Q: 统一模型网关 的事件摄取吞吐 (events/s) 是多少?

A: A: 依据 P001-F002: 事件摄取吞吐 = 185000 events/s, 约束 enterprise-edition、3-node。

否定事实与边界

边界事实 (must-not-claim) : 仅企业版支持多租户路由策略。

边界事实: 统一模型网关 不支持 不支持 gRPC 负载均衡到旧 v2.0 网关节点 (详见 P001-F 系事实)。

边界事实 (must-not-claim) : 不支持 QUIC 传输协议。

边界事实: 统一模型网关 不支持 不支持 gRPC 负载均衡到旧 v2.0 网关节点 (详见 P001-F 系事实)。