

LLM 安全网关常见问题 (FAQ)

FAQ 章节 1

Q: Q: LLM 安全网关 的核心协议 () 是多少?

A: A: 依据 P014-F261: 核心协议 = ['提示注入拦截', 'PII 检测', '策略旁路'], 约束 支持 提示注入拦截、支持 PII 检测、支持 策略旁路。

Q: Q: LLM 安全网关 的事件摄取吞吐 (events/s) 是多少?

A: A: 依据 P014-F262: 事件摄取吞吐 = 760000 events/s, 约束 enterprise-edition、3-node。

Q: Q: LLM 安全网关 的 API 峰值并发 (req/s) 是多少?

A: A: 依据 P014-F263: API 峰值并发 = 15000 req/s, 约束 enterprise-edition。

Q: Q: LLM 安全网关 的 P95 检索延迟 (ms) 是多少?

A: A: 依据 P014-F264: P95 检索延迟 = 35 ms, 约束 p95、warm。

Q: Q: LLM 安全网关 的最大单文档上传 (MB) 是多少?

A: A: 依据 P014-F265: 最大单文档上传 = 32 MB, 约束 默认限制。

Q: Q: LLM 安全网关 的日志/审计留存期 (days) 是多少?

A: A: 依据 P014-F266: 日志/审计留存期 = 90 days, 约束 默认。

Q: Q: LLM 安全网关 的批量接口吞吐 (ops/s) 是多少?

A: A: 依据 P014-F267: 批量接口吞吐 = 9800 ops/s, 约束 batch=256。

Q: Q: LLM 安全网关 的当前版本线 (version) 是多少?

A: A: 依据 P014-F268: 当前版本线 = v5.0 version, 约束 GA。

Q: Q: LLM 安全网关 的默认批次大小 (items) 是多少?

A: A: 依据 P014-F269: 默认批次大小 = 256 items, 约束 可配置。

Q: Q: LLM 安全网关 的不支持能力 () 是多少?

A: A: 依据 P014-F270: 不支持能力 = 不支持对模型参数优化的注水拦截, 约束 negation。

Q: Q: LLM 安全网关 的否定事实 () 是多少?

A: A: 依据 P014-F271: 否定事实 = 仅企业版支持 ML 注入检测, 约束 negation、must-not-claim。

Q: Q: LLM 安全网关 的否定事实 () 是多少?

A: A: 依据 P014-F272: 否定事实 = 不支持原生端到端全模型脱敏, 约束 negation、must-not-claim。

Q: Q: LLM 安全网关 的可用性目标 (percent) 是多少?

A: A: 依据 P014-F273: 可用性目标 = 99.9 percent, 约束 enterprise-SLA。

Q: Q: LLM 安全网关 的合规基座 () 是多少?

A: A: 依据 P014-F274: 合规基座 = GB-35273/CAC-审查-P014, 约束 zh-cn。

Q: Q: LLM 安全网关 的企业版起价 (cny/月) 是多少?

A: A: 依据 P014-F275: 企业版起价 = 19180 cny/月, 约束 per-org、annual。

Q: Q: LLM 安全网关 的主邻接产品 (product) 是多少?

A: A: 依据 P014-F276: 主邻接产品 = P001 product, 约束 邻接 P001。

Q: Q: LLM 安全网关 的旧版事件吞吐 (events/s) 是多少?

A: A: 依据 P014-F277: 旧版事件吞吐 = 471200 events/s, 约束 v4.9、legacy。

Q: Q: LLM 安全网关 的旧版 P95 延迟 (ms) 是多少?

A: A: 依据 P014-F278: 旧版 P95 延迟 = 59 ms, 约束 v4.9、legacy。

Q: Q: LLM 安全网关 的与 P001 兼容 (bool) 是多少?

A: A: 依据 P014-F279: 与 P001 兼容 = true bool, 约束 edge P014->P001。

Q: Q: LLM 安全网关 的与 P007 兼容 (bool) 是多少?

A: A: 依据 P014-F280: 与 P007 兼容 = true bool, 约束 edge P014->P007。

FAQ 章节 2

Q: Q: LLM 安全网关 的事件摄取吞吐 (events/s) 是多少?

A: A: 依据 P014-F262: 事件摄取吞吐 = 760000 events/s, 约束 enterprise-edition、3-node。

Q: Q: LLM 安全网关 的 API 峰值并发 (req/s) 是多少?

A: A: 依据 P014-F263: API 峰值并发 = 15000 req/s, 约束 enterprise-edition。

Q: Q: LLM 安全网关 的 P95 检索延迟 (ms) 是多少?

A: A: 依据 P014-F264: P95 检索延迟 = 35 ms, 约束 p95、warm。

Q: Q: LLM 安全网关 的最大单文档上传 (MB) 是多少?

A: A: 依据 P014-F265: 最大单文档上传 = 32 MB, 约束 默认限制。

Q: Q: LLM 安全网关 的日志/审计留存期 (days) 是多少?

A: A: 依据 P014-F266: 日志/审计留存期 = 90 days, 约束 默认。

Q: Q: LLM 安全网关 的批量接口吞吐 (ops/s) 是多少?

A: A: 依据 P014-F267: 批量接口吞吐 = 9800 ops/s, 约束 batch=256。

Q: Q: LLM 安全网关 的当前版本线 (version) 是多少?

A: A: 依据 P014-F268: 当前版本线 = v5.0 version, 约束 GA。

Q: Q: LLM 安全网关 的 默认批次大小 (items) 是多少?
A: A: 依据 P014-F269: 默认批次大小 = 256 items, 约束 可配置。
Q: Q: LLM 安全网关 的 不支持能力 () 是多少?
A: A: 依据 P014-F270: 不支持能力 = 不支持对模型参数优化的注水拦截, 约束 negation。
Q: Q: LLM 安全网关 的 否定事实 () 是多少?
A: A: 依据 P014-F271: 否定事实 = 仅企业版支持 ML 注入检测, 约束 negation、must-not-claim。
Q: Q: LLM 安全网关 的 否定事实 () 是多少?
A: A: 依据 P014-F272: 否定事实 = 不支持原生端到端全模型脱敏, 约束 negation、must-not-claim。
Q: Q: LLM 安全网关 的 可用性目标 (percent) 是多少?
A: A: 依据 P014-F273: 可用性目标 = 99.9 percent, 约束 enterprise-SLA。
Q: Q: LLM 安全网关 的 合规基座 () 是多少?
A: A: 依据 P014-F274: 合规基座 = GB-35273/CAC-审查-P014, 约束 zh-cn。
Q: Q: LLM 安全网关 的 企业版起价 (cny/月) 是多少?
A: A: 依据 P014-F275: 企业版起价 = 19180 cny/月, 约束 per-org、annual。
Q: Q: LLM 安全网关 的 主邻接产品 (product) 是多少?
A: A: 依据 P014-F276: 主邻接产品 = P001 product, 约束 邻接 P001。
Q: Q: LLM 安全网关 的 旧版事件吞吐 (events/s) 是多少?
A: A: 依据 P014-F277: 旧版事件吞吐 = 471200 events/s, 约束 v4.9、legacy。
Q: Q: LLM 安全网关 的 旧版 P95 延迟 (ms) 是多少?
A: A: 依据 P014-F278: 旧版 P95 延迟 = 59 ms, 约束 v4.9、legacy。
Q: Q: LLM 安全网关 的 与 P001 兼容 (bool) 是多少?
A: A: 依据 P014-F279: 与 P001 兼容 = true bool, 约束 edge P014->P001。
Q: Q: LLM 安全网关 的 与 P007 兼容 (bool) 是多少?
A: A: 依据 P014-F280: 与 P007 兼容 = true bool, 约束 edge P014->P007。
Q: Q: LLM 安全网关 的 核心协议 () 是多少?
A: A: 依据 P014-F261: 核心协议 = ['提示注入拦截', 'PII 检测', '策略旁路'], 约束 支持 提示注入拦截、支持 PII 检测、支持 策略旁路。

FAQ 章节 3

Q: Q: LLM 安全网关 的 API 峰值并发 (req/s) 是多少?
A: A: 依据 P014-F263: API 峰值并发 = 15000 req/s, 约束 enterprise-edition。
Q: Q: LLM 安全网关 的 P95 检索延迟 (ms) 是多少?
A: A: 依据 P014-F264: P95 检索延迟 = 35 ms, 约束 p95、warm。
Q: Q: LLM 安全网关 的 最大单文档上传 (MB) 是多少?
A: A: 依据 P014-F265: 最大单文档上传 = 32 MB, 约束 默认限制。
Q: Q: LLM 安全网关 的 日志/审计留存期 (days) 是多少?
A: A: 依据 P014-F266: 日志/审计留存期 = 90 days, 约束 默认。
Q: Q: LLM 安全网关 的 批量接口吞吐 (ops/s) 是多少?
A: A: 依据 P014-F267: 批量接口吞吐 = 9800 ops/s, 约束 batch=256。
Q: Q: LLM 安全网关 的 当前版本线 (version) 是多少?
A: A: 依据 P014-F268: 当前版本线 = v5.0 version, 约束 GA。
Q: Q: LLM 安全网关 的 默认批次大小 (items) 是多少?
A: A: 依据 P014-F269: 默认批次大小 = 256 items, 约束 可配置。
Q: Q: LLM 安全网关 的 不支持能力 () 是多少?
A: A: 依据 P014-F270: 不支持能力 = 不支持对模型参数优化的注水拦截, 约束 negation。
Q: Q: LLM 安全网关 的 否定事实 () 是多少?
A: A: 依据 P014-F271: 否定事实 = 仅企业版支持 ML 注入检测, 约束 negation、must-not-claim。
Q: Q: LLM 安全网关 的 否定事实 () 是多少?
A: A: 依据 P014-F272: 否定事实 = 不支持原生端到端全模型脱敏, 约束 negation、must-not-claim。
Q: Q: LLM 安全网关 的 可用性目标 (percent) 是多少?
A: A: 依据 P014-F273: 可用性目标 = 99.9 percent, 约束 enterprise-SLA。
Q: Q: LLM 安全网关 的 合规基座 () 是多少?
A: A: 依据 P014-F274: 合规基座 = GB-35273/CAC-审查-P014, 约束 zh-cn。
Q: Q: LLM 安全网关 的 企业版起价 (cny/月) 是多少?
A: A: 依据 P014-F275: 企业版起价 = 19180 cny/月, 约束 per-org、annual。
Q: Q: LLM 安全网关 的 主邻接产品 (product) 是多少?
A: A: 依据 P014-F276: 主邻接产品 = P001 product, 约束 邻接 P001。
Q: Q: LLM 安全网关 的 旧版事件吞吐 (events/s) 是多少?
A: A: 依据 P014-F277: 旧版事件吞吐 = 471200 events/s, 约束 v4.9、legacy。

Q: Q: LLM 安全网关 的 旧版 P95 延迟 (ms) 是多少?

A: A: 依据 P014-F278: 旧版 P95 延迟 = 59 ms, 约束 v4.9、legacy。

Q: Q: LLM 安全网关 的 与 P001 兼容 (bool) 是多少?

A: A: 依据 P014-F279: 与 P001 兼容 = true bool, 约束 edge P014->P001。

Q: Q: LLM 安全网关 的 与 P007 兼容 (bool) 是多少?

A: A: 依据 P014-F280: 与 P007 兼容 = true bool, 约束 edge P014->P007。

Q: Q: LLM 安全网关 的核心协议 () 是多少?

A: A: 依据 P014-F261: 核心协议 = ['提示注入拦截', 'PII 检测', '策略旁路'], 约束 支持 提示注入拦截、支持 PII 检测、支持 策略旁路。

Q: Q: LLM 安全网关 的事件摄取吞吐 (events/s) 是多少?

A: A: 依据 P014-F262: 事件摄取吞吐 = 760000 events/s, 约束 enterprise-edition、3-node。

否定事实与边界

边界事实 (must-not-claim) : 仅企业版支持 ML 注入检测。

边界事实: LLM 安全网关 不支持 不支持对模型参数优化的注水拦截 (详见 P014-F 系事实)。

边界事实 (must-not-claim) : 不支持原生端到端全模型脱敏。

边界事实: LLM 安全网关 不支持 不支持对模型参数优化的注水拦截 (详见 P014-F 系事实)。