

推理成本治理常见问题 (FAQ)

FAQ 章节 1

Q: Q: 推理成本治理 的核心协议 () 是多少?

A: A: 依据 P017-F321: 核心协议 = ['预算聚合', '单位成本口径'], 约束 支持 预算聚合、支持 单位成本口径。

Q: Q: 推理成本治理 的事件摄取吞吐 (events/s) 是多少?

A: A: 依据 P017-F322: 事件摄取吞吐 = 40000 events/s, 约束 standard-edition、3-node。

Q: Q: 推理成本治理 的 API 峰值并发 (req/s) 是多少?

A: A: 依据 P017-F323: API 峰值并发 = 800 req/s, 约束 standard-edition。

Q: Q: 推理成本治理 的 P95 检索延迟 (ms) 是多少?

A: A: 依据 P017-F324: P95 检索延迟 = 34 ms, 约束 p95、warm。

Q: Q: 推理成本治理 的最大单文档上传 (MB) 是多少?

A: A: 依据 P017-F325: 最大单文档上传 = 2 MB, 约束 默认限制。

Q: Q: 推理成本治理 的日志/审计留存期 (days) 是多少?

A: A: 依据 P017-F326: 日志/审计留存期 = 60 days, 约束 默认。

Q: Q: 推理成本治理 的批量接口吞吐 (ops/s) 是多少?

A: A: 依据 P017-F327: 批量接口吞吐 = 900 ops/s, 约束 batch=64。

Q: Q: 推理成本治理 的当前版本线 (version) 是多少?

A: A: 依据 P017-F328: 当前版本线 = v1.2 version, 约束 GA。

Q: Q: 推理成本治理 的默认批次大小 (items) 是多少?

A: A: 依据 P017-F329: 默认批次大小 = 64 items, 约束 可配置。

Q: Q: 推理成本治理 的不支持能力 () 是多少?

A: A: 依据 P017-F330: 不支持能力 = 不支持按 token 精度的跨账期分摊, 约束 negation。

Q: Q: 推理成本治理 的否定事实 () 是多少?

A: A: 依据 P017-F331: 否定事实 = 预算告警仅覆盖主折线, 约束 negation、must-not-claim。

Q: Q: 推理成本治理 的否定事实 () 是多少?

A: A: 依据 P017-F332: 否定事实 = 不支持 Spot 波动定价的预测, 约束 negation、must-not-claim。

Q: Q: 推理成本治理 的可用性目标 (percent) 是多少?

A: A: 依据 P017-F333: 可用性目标 = 99.9 percent, 约束 standard-SLA。

Q: Q: 推理成本治理 的合规基座 () 是多少?

A: A: 依据 P017-F334: 合规基座 = GB-35273/CAC-审查-P017, 约束 zh-cn。

Q: Q: 推理成本治理 的企业版起价 (cny/月) 是多少?

A: A: 依据 P017-F335: 企业版起价 = 23290 cny/月, 约束 per-org、annual。

Q: Q: 推理成本治理 的主邻接产品 (product) 是多少?

A: A: 依据 P017-F336: 主邻接产品 = P001 product, 约束 邻接 P001。

Q: Q: 推理成本治理 的与 P001 兼容 (bool) 是多少?

A: A: 依据 P017-F337: 与 P001 兼容 = true bool, 约束 edge P017->P001。

Q: Q: 推理成本治理 的与 P019 兼容 (bool) 是多少?

A: A: 依据 P017-F338: 与 P019 兼容 = true bool, 约束 edge P017->P019。

FAQ 章节 2

Q: Q: 推理成本治理 的事件摄取吞吐 (events/s) 是多少?

A: A: 依据 P017-F322: 事件摄取吞吐 = 40000 events/s, 约束 standard-edition、3-node。

Q: Q: 推理成本治理 的 API 峰值并发 (req/s) 是多少?

A: A: 依据 P017-F323: API 峰值并发 = 800 req/s, 约束 standard-edition。

Q: Q: 推理成本治理 的 P95 检索延迟 (ms) 是多少?

A: A: 依据 P017-F324: P95 检索延迟 = 34 ms, 约束 p95、warm。

Q: Q: 推理成本治理 的最大单文档上传 (MB) 是多少?

A: A: 依据 P017-F325: 最大单文档上传 = 2 MB, 约束 默认限制。

Q: Q: 推理成本治理 的日志/审计留存期 (days) 是多少?

A: A: 依据 P017-F326: 日志/审计留存期 = 60 days, 约束 默认。

Q: Q: 推理成本治理 的批量接口吞吐 (ops/s) 是多少?

A: A: 依据 P017-F327: 批量接口吞吐 = 900 ops/s, 约束 batch=64。

Q: Q: 推理成本治理 的当前版本线 (version) 是多少?

A: A: 依据 P017-F328: 当前版本线 = v1.2 version, 约束 GA。

Q: Q: 推理成本治理 的默认批次大小 (items) 是多少?

A: A: 依据 P017-F329: 默认批次大小 = 64 items, 约束 可配置。

Q: Q: 推理成本治理 的不支持能力 () 是多少?

A: A: 依据 P017-F330: 不支持能力 = 不支持按 token 精度的跨账期分摊, 约束 negation。

Q: Q: 推理成本治理 的否定事实 () 是多少?

A: A: 依据 P017-F331: 否定事实 = 预算告警仅覆盖主折线, 约束 negation、must-not-claim。
Q: Q: 推理成本治理 的 否定事实 () 是多少?
A: A: 依据 P017-F332: 否定事实 = 不支持 Spot 波动定价的预测, 约束 negation、must-not-claim。
Q: Q: 推理成本治理 的 可用性目标 (percent) 是多少?
A: A: 依据 P017-F333: 可用性目标 = 99.9 percent, 约束 standard-SLA。
Q: Q: 推理成本治理 的 合规基座 () 是多少?
A: A: 依据 P017-F334: 合规基座 = GB-35273/CAC-审查-P017, 约束 zh-cn。
Q: Q: 推理成本治理 的 企业版起价 (cny/月) 是多少?
A: A: 依据 P017-F335: 企业版起价 = 23290 cny/月, 约束 per-org、annual。
Q: Q: 推理成本治理 的 主邻接产品 (product) 是多少?
A: A: 依据 P017-F336: 主邻接产品 = P001 product, 约束 邻接 P001。
Q: Q: 推理成本治理 的 与 P001 兼容 (bool) 是多少?
A: A: 依据 P017-F337: 与 P001 兼容 = true bool, 约束 edge P017->P001。
Q: Q: 推理成本治理 的 与 P019 兼容 (bool) 是多少?
A: A: 依据 P017-F338: 与 P019 兼容 = true bool, 约束 edge P017->P019。
Q: Q: 推理成本治理 的 核心协议 () 是多少?
A: A: 依据 P017-F321: 核心协议 = ['预算聚合', '单位成本口径'], 约束 支持 预算聚合、支持 单位成本口径。

FAQ 章节 3

Q: Q: 推理成本治理 的 API 峰值并发 (req/s) 是多少?
A: A: 依据 P017-F323: API 峰值并发 = 800 req/s, 约束 standard-edition。
Q: Q: 推理成本治理 的 P95 检索延迟 (ms) 是多少?
A: A: 依据 P017-F324: P95 检索延迟 = 34 ms, 约束 p95、warm。
Q: Q: 推理成本治理 的 最大单文档上传 (MB) 是多少?
A: A: 依据 P017-F325: 最大单文档上传 = 2 MB, 约束 默认限制。
Q: Q: 推理成本治理 的 日志/审计留存期 (days) 是多少?
A: A: 依据 P017-F326: 日志/审计留存期 = 60 days, 约束 默认。
Q: Q: 推理成本治理 的 批量接口吞吐 (ops/s) 是多少?
A: A: 依据 P017-F327: 批量接口吞吐 = 900 ops/s, 约束 batch=64。
Q: Q: 推理成本治理 的 当前版本线 (version) 是多少?
A: A: 依据 P017-F328: 当前版本线 = v1.2 version, 约束 GA。
Q: Q: 推理成本治理 的 默认批次大小 (items) 是多少?
A: A: 依据 P017-F329: 默认批次大小 = 64 items, 约束 可配置。
Q: Q: 推理成本治理 的 不支持能力 () 是多少?
A: A: 依据 P017-F330: 不支持能力 = 不支持按 token 精度的跨账期分摊, 约束 negation。
Q: Q: 推理成本治理 的 否定事实 () 是多少?
A: A: 依据 P017-F331: 否定事实 = 预算告警仅覆盖主折线, 约束 negation、must-not-claim。
Q: Q: 推理成本治理 的 否定事实 () 是多少?
A: A: 依据 P017-F332: 否定事实 = 不支持 Spot 波动定价的预测, 约束 negation、must-not-claim。
Q: Q: 推理成本治理 的 可用性目标 (percent) 是多少?
A: A: 依据 P017-F333: 可用性目标 = 99.9 percent, 约束 standard-SLA。
Q: Q: 推理成本治理 的 合规基座 () 是多少?
A: A: 依据 P017-F334: 合规基座 = GB-35273/CAC-审查-P017, 约束 zh-cn。
Q: Q: 推理成本治理 的 企业版起价 (cny/月) 是多少?
A: A: 依据 P017-F335: 企业版起价 = 23290 cny/月, 约束 per-org、annual。
Q: Q: 推理成本治理 的 主邻接产品 (product) 是多少?
A: A: 依据 P017-F336: 主邻接产品 = P001 product, 约束 邻接 P001。
Q: Q: 推理成本治理 的 与 P001 兼容 (bool) 是多少?
A: A: 依据 P017-F337: 与 P001 兼容 = true bool, 约束 edge P017->P001。
Q: Q: 推理成本治理 的 与 P019 兼容 (bool) 是多少?
A: A: 依据 P017-F338: 与 P019 兼容 = true bool, 约束 edge P017->P019。
Q: Q: 推理成本治理 的 核心协议 () 是多少?
A: A: 依据 P017-F321: 核心协议 = ['预算聚合', '单位成本口径'], 约束 支持 预算聚合、支持 单位成本口径。
Q: Q: 推理成本治理 的 事件摄取吞吐 (events/s) 是多少?
A: A: 依据 P017-F322: 事件摄取吞吐 = 40000 events/s, 约束 standard-edition、3-node。

否定事实与边界

边界事实 (must-not-claim): 预算告警仅覆盖主折线。

边界事实: 推理成本治理 不支持 不支持按 token 精度的跨账期分摊 (详见 P017-F 系事实)。

边界事实 (must-not-claim): 不支持 Spot 波动定价的预测。

边界事实：推理成本治理 不支持 不支持按 token 精度的跨账期分摊（详见 P017-F 系事实）。