

推理成本治理·compliance·v1.2-cn (政策/条款文档)

适用范围

条款组 1

- > 第 1 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 核心协议 明确口径为 预算聚合、单位成本口径，约束包括支持 预算聚合、支持 单位成本口径；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。
- > 第 2 条 推理成本治理 的事件摄取吞吐应遵循 40000 events/s 的既定标准，适用限定standard-edition、3-node。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。
- > 第 3 条 依据企业级规章制度，推理成本治理 将API 峰值并发的管理规范确定为 800 req/s，并以 standard-edition 作为例外边界；违反者进入审计台账。
- > 第 4 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于P95 检索延迟的规定为 34 ms，限定p95、warm，适用于 v1.2-cn 及其后继发布。
- > 第 5 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 最大单文档上传 明确口径为 2 MB，约束包括默认限制；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。
- > 第 6 条 推理成本治理 的日志/审计留存期应遵循 60 days 的既定标准，适用限定默认。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。
- > 第 7 条 依据企业级规章制度，推理成本治理 将批量接口吞吐的管理规范确定为 900 ops/s，并以 batch=64 作为例外边界；违反者进入审计台账。
- > 第 8 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于当前版本线的规定为 v1.2 version，限定GA，适用于 v1.2-cn 及其后继发布。
- > 第 9 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 默认批次大小 明确口径为 64 items，约束包括可配置；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。
- > 第 10 条 推理成本治理 的不支持能力应遵循 不支持按 token 精度的跨账期分摊 的既定标准，适用限定negation。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。
- > 第 11 条 依据企业级规章制度，推理成本治理 将否定事实的管理规范确定为 预算告警仅覆盖主折线，并以 negation、must-not-claim 作为例外边界；违反者进入审计台账。
- > 第 12 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于否定事实的规定为 不支持 Spot 波动定价的预测，限定negation、must-not-claim，适用于 v1.2-cn 及其后继发布。
- > 第 13 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 可用性目标 明确口径为 99.9 percent，约束包括standard-SLA；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。
- > 第 14 条 推理成本治理 的合规基座应遵循 GB-35273/CAC-审查-P017 的既定标准，适用限定zh-cn。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。
- > 第 15 条 依据企业级规章制度，推理成本治理 将企业版起价的管理规范确定为 23290 cny/月，并以 per-org、annual 作为例外边界；违反者进入审计台账。
- > 第 16 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于主邻接产品的规定为 P001 product，限定邻接 P001，适用于 v1.2-cn 及其后继发布。
- > 第 17 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 与 P001 兼容 明确口径为 true bool，约束包括edge P017->P001；该条款自 2025-02-01 起对其在 v1.2-cn 及后续补丁版本持续有效。
- > 第 18 条 推理成本治理 的与 P019 兼容应遵循 true bool 的既定标准，适用限定edge P017->P019。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。

总体原则与规范

条款组 2

- > 第 19 条 推理成本治理 的事件摄取吞吐应遵循 40000 events/s 的既定标准，适用限定standard-edition、3-node。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。
- > 第 20 条 依据企业级规章制度，推理成本治理 将API 峰值并发的管理规范确定为 800 req/s，并以 standard-edition 作为例外边界；违反者进入审计台账。
- > 第 21 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于P95 检索延迟的规定为 34 ms，限定p95、warm，适用于 v1.2-cn 及其后继发布。
- > 第 22 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 最大单文档上传 明确口径为 2 MB，约束包括默认限制；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。
- > 第 23 条 推理成本治理 的日志/审计留存期应遵循 60 days 的既定标准，适用限定默认。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。
- > 第 24 条 依据企业级规章制度，推理成本治理 将批量接口吞吐的管理规范确定为 900 ops/s，并以 batch=64

作为例外边界；违反者进入审计台账。

> 第 25 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于当前版本线的规定为 v1.2 version，限定GA，适用于 v1.2-cn 及其后继发布。

> 第 26 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 默认批次大小明确口径为 64 items，约束包括可配置；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。

> 第 27 条 推理成本治理 的不支持能力应遵循 不支持按 token 精度的跨账期分摊的既定标准，适用限定negation。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。

> 第 28 条 依据企业级规章制度，推理成本治理 将否定事实的管理规范确定为 预算告警仅覆盖主折线，并以 negation、must-not-claim 作为例外边界；违反者进入审计台账。

> 第 29 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于否定事实的规定为 不支持 Spot 波动定价的预测，限定negation、must-not-claim，适用于 v1.2-cn 及其后继发布。

> 第 30 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 可用性目标明确口径为 99.9 percent，约束包括standard-SLA；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。

> 第 31 条 推理成本治理 的合规基座应遵循 GB-35273/CAC-审查-P017 的既定标准，适用限定zh-cn。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。

> 第 32 条 依据企业级规章制度，推理成本治理 将企业版起价的管理规范确定为 23290 cny/月，并以 per-org、annual 作为例外边界；违反者进入审计台账。

> 第 33 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于主邻接产品的规定为 P001 product，限定邻接 P001，适用于 v1.2-cn 及其后继发布。

> 第 34 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 与 P001 兼容明确口径为 true bool，约束包括edge P017->P001；该条款自 2025-02-01 起对其在 v1.2-cn 及后续补丁版本持续有效。

> 第 35 条 推理成本治理 的与 P019 兼容应遵循 true bool 的既定标准，适用限定edge P017->P019。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。

> 第 36 条 依据企业级规章制度，推理成本治理 将核心协议的管理规范确定为 预算聚合、单位成本口径，并以支持 预算聚合、支持 单位成本口径 作为例外边界；违反者进入审计台账。

性能与容量条款

条款组 3

> 第 37 条 依据企业级规章制度，推理成本治理 将API 峰值并发的管理规范确定为 800 req/s，并以 standard-edition 作为例外边界；违反者进入审计台账。

> 第 38 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于P95 检索延迟的规定为 34 ms，限定p95、warm，适用于 v1.2-cn 及其后继发布。

> 第 39 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 最大单文档上传明确口径为 2 MB，约束包括默认限制；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。

> 第 40 条 推理成本治理 的日志/审计留存期应遵循 60 days 的既定标准，适用限定默认。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。

> 第 41 条 依据企业级规章制度，推理成本治理 将批量接口吞吐的管理规范确定为 900 ops/s，并以 batch=64 作为例外边界；违反者进入审计台账。

> 第 42 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于当前版本线的规定为 v1.2 version，限定GA，适用于 v1.2-cn 及其后继发布。

> 第 43 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 默认批次大小明确口径为 64 items，约束包括可配置；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。

> 第 44 条 推理成本治理 的不支持能力应遵循 不支持按 token 精度的跨账期分摊的既定标准，适用限定negation。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。

> 第 45 条 依据企业级规章制度，推理成本治理 将否定事实的管理规范确定为 预算告警仅覆盖主折线，并以 negation、must-not-claim 作为例外边界；违反者进入审计台账。

> 第 46 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于否定事实的规定为 不支持 Spot 波动定价的预测，限定negation、must-not-claim，适用于 v1.2-cn 及其后继发布。

> 第 47 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就 可用性目标明确口径为 99.9 percent，约束包括standard-SLA；该条款自 2025-01-01 起对其在 v1.2-cn 及后续补丁版本持续有效。

> 第 48 条 推理成本治理 的合规基座应遵循 GB-35273/CAC-审查-P017 的既定标准，适用限定zh-cn。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。

> 第 49 条 依据企业级规章制度，推理成本治理 将企业版起价的管理规范确定为 23290 cny/月，并以 per-org、annual 作为例外边界；违反者进入审计台账。

> 第 50 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于主邻接产品的规定为 P001 product，限定邻接 P001，适用于 v1.2-cn 及其后继发布。

> 第 51 条 为确保AI 基础设施、推理平台和成本治理的合规与可审计性，推理成本治理 就与 P001 兼容明确口径为 true bool，约束包括edge P017->P001；该条款自 2025-02-01 起对其在 v1.2-cn 及后续补丁版本持续有效。

> 第 52 条 推理成本治理 的与 P019 兼容应遵循 true bool 的既定标准，适用限定edge P017->P019。本细则覆盖 cn 区域与 AI 基础设施、推理平台和成本治理 场景，属于强制规范。

> 第 53 条 依据企业级规章制度，推理成本治理 将核心协议的管理规范确定为 预算聚合、单位成本口径，并以支持 预算聚合、支持 单位成本口径 作为例外边界；违反者进入审计台账。

> 第 54 条 在AI 基础设施、推理平台和成本治理 治理条例框架内，推理成本治理 关于事件摄取吞吐的规定为 40000 events/s，限定standard-edition、3-node，适用于 v1.2-cn 及其后继发布。

否定事实与边界

边界事实 (must-not-claim)：预算告警仅覆盖主折线。

边界事实：推理成本治理 不支持 不支持按 token 精度的跨账期分摊（详见 P017-F 系事实）。

边界事实 (must-not-claim)：不支持 Spot 波动定价的预测。

边界事实：推理成本治理 不支持 不支持按 token 精度的跨账期分摊（详见 P017-F 系事实）。